

Quelques éléments d'introduction au niveau physique/interne d'un SGBD - stockage


Géraldine Del Mondo

Département Informatique et Technologies de l'information

Institut National des Sciences Appliquées - Rouen


geraldine.del_mondo@insa-rouen.fr

Trois niveaux d'abstraction ANSI/X3/SPARC - 1975



Conception d'une BD : principes généraux

Schémas



Définition d'un SGBD



• But


- Faciliter l'accès aux données
- Cacher la représentation physique aux applications

• Fonctions

- Langage de définition et de manipulation
- **Stockage et méthodes d'accès aux données**
- **Concurrence et reprise sur panne**
- Gestion des droits, répartition des données
- Interface avec les langages de programmation

• Comment ?

- Vision de haut niveau via un modèle **logique** de données
- Assurer la correspondance physique / logique



Langage de Définition de Données - LDD (DDL : Data Definition Language)



LDD

- Définition logique des données
 - Schéma conceptuel global (données et liens entre les données)
 - Schémas des vues utilisateurs (3ème niveau ANSI/SPARC)
- **Définition physique des données**
 - **Schéma physique des données**
 - **Méthodes de placement et d'accès**
- Contrôle des données
 - Contraintes d'intégrité
 - Droits d'accès

➔ **Entités concernées : administrateur de la base et le SGBD**

Stockage

Les objets à stocker

- **Les relations système**
 - ↳ Description de la base
 - ↳ BD système
- **Les relations utilisateur**
 - ↳ Données utilisateur
- **Les index**
 - ↳ Sur les relations utilisateur
(accélérer les accès aux données)

Organisation du stockage séquentiel...

Relation Personnes

Id	Nom	AnneeNaiss	Adresse
3	A	1950	...
2	R	1980	...
4	C	2000	...
1	B	1968	...

3	A	1950	...	2	R	1980	...	4	C	2000	...	1	B	...
---	---	------	-----	---	---	------	-----	---	---	------	-----	---	---	-----

1	B	1968	...	2	R	1980	...	3	A	1950	...	4	C	...
---	---	------	-----	---	---	------	-----	---	---	------	-----	---	---	-----


3	A	1950	...	1	B	1968	...	4	C	2000	...	2	R	...
---	---	------	-----	---	---	------	-----	---	---	------	-----	---	---	-----

Organisation du stockage indexation...


Relation Personnes

Id	Nom	AnneeNaiss	Adresse
1	B	1968	...
2	R	1980	...
3	A	1950	...
4	C	2000	...

(↑ Vue logique)





Exemples d'index



Taille d'un bloc = 4

- $h(\text{titre}) = \text{rang}(\text{titre}[0] \bmod 5)$

Impitoyable $\rightarrow$ 'I' $\rightarrow 9, 9 \bmod 5 = 4$



Questions

- Comment je **range** mes données ?
- Comment j'**accède** à mes données ?

Volume de données

Types de requêtes

Le besoin

→ **Ranger** : méthodes d'organisation/de **placement**

→ **Accéder** : méthodes de recherche/d'**accès**

Questions

- Comment je **range** mes données ?
- Comment j'**accède** à mes données ?

Volume de données

Types de requêtes

Le besoin

→ **Ranger** : méthodes d'organisation/de **placement**

→ **Accéder** : méthodes de recherche/d'**accès**

Organisation/Placement

Définition PLACEMENT

Méthode d'organisation (rangement) des tuples d'une relation sur disque en fonction des valeurs d'un attribut ou d'un groupe d'attributs.

Méthodes :

- Placement séquentiel (trié/non trié)
- Placement indexé
- Placement par hachage

Caractéristiques de placement

(clé de placement)

- Mono-attribut OU Multi-attributs
- Clé primaire OU non
- Comparaison de clés OU calcul
- Statique OU Dynamique

(Ces caractéristiques ne concernent pas le séquentiel non trié !)

Recherche/Accès



Définition ACCÈS

Méthode de recherche d'un tuple ou d'un groupe de tuples d'une relation en fonction de la valeur d'un attribut ou d'un groupe d'attributs.

Méthodes :

- Accès séquentiel
- Accès sélectif (direct)

Caractéristiques de recherche

(clé de recherche)

Recherche de tous les tuples d'une relation :

- Ordre quelconque
- Critère de tri

Recherche sélective :

- Mono-attribut OU Multi-attributs
- Clé primaire OU Autre
- Valeur exacte OU Intervalle

Notez bien

Il ne faut pas confondre l'**organisation** des données qui répond à des méthodes basées sur des caractéristiques de **placement**, et l'**accès** aux données qui fait référence à des méthodes basées sur des caractéristiques de **sélection**.

Objectifs des méthodes de placement et d'accès

- **Limitation des accès aux seules données pertinentes afin de minimiser le nombre d'E/S disque**
- **Adaptation à la croissance du volume des données de la base**
- Efficacité de la recherche d'un ensemble de tuples vérifiant un critère multi-attributs
- Amélioration des algorithmes de sélection et de jointure

Concepteur BD → choix d'une méthode équilibrée entre le temps mis pour accéder aux données et l'espace mémoire utilisé.

Concrètement....

Les chemins d'accès primaires



Définition ACCÈS PRIMAIRE

Accès associé au placement d'une relation

EXEMPLE : Relation R placée sur un attribut A

- Placement séquentiel trié
 - Séquentiel trié sur A
- Placement indexé
 - Séquentiel trié sur A
 - Direct sur A via l'index
- Placement par hachage
 - Direct sur A via la fonction de hachage

Les accès secondaires

Hypothèse : Relation R placée sur un attribut A

Problème

- Favorise les accès sur A
- ↪ Défavorise les accès $\neq A$

Solution

- Création d'un chemin d'accès alternatif pour accélérer les accès sur un autre attribut B : un **index secondaire** sur B

Index secondaire

Définition INDEX SECONDAIRE

- Associe à chaque valeur V de l'attribut indexé les tuples de R ayant V comme valeur de l'attribut B
- Relation de schéma (Attribut_indexé, Identifiant_tuple)
En général implantée comme un arbre- B
- Index non discriminant

Relation R

Etu	nomEtu
1	Zaber
2	Habiche
3	Madelin
4	Briochin

Index Primaire

Etu	@Tuple
1	@Tuple1
2	@Tuple2
3	@Tuple3
4	@Tuple4

Index Secondaire

nomEtu	@Tuple
Briochin	@Tuple4
Habiche	@Tuple2
Madelin	@Tuple3
Zaber	@Tuple1

CREATE INDEX *nom_index_secondaire* **ON** R(*nomEtu*);

Index secondaire

Définition INDEX SECONDAIRE

- Associe à chaque valeur V de l'attribut indexé les tuples de R ayant V comme valeur de l'attribut B
- Relation de schéma (Attribut_indexé, Identifiant_tuple)
En général implantée comme un arbre- B
- Index non discriminant

Relation R

Etu	nomEtu
1	Zaber
2	Habiche
3	Madelin
4	Briochin

Index Primaire

Etu	@Tuple
1	@Tuple1
2	@Tuple2
3	@Tuple3
4	@Tuple4

Index Secondaire

nomEtu	@Tuple
Briochin	@Tuple4
Habiche	@Tuple2
Madelin	@Tuple3
Zaber	@Tuple1

CREATE INDEX *nom_index_secondaire* **ON** R(*nomEtu*) ;

- 1 méthode de placement
 - ➔ potentiellement plusieurs méthodes d'accès
- La méthode utilisée pour le placement des données peut-être différente de(s) la méthode(s) d'accès à ces données.
- L'utilisation d'un index n'est pas toujours souhaitable (notion de sélectivité, évaluation via plan d'exécution)

Conclusion

Nous avons vu...

- une introduction au niveau physique/interne du SGBD
- quelques éléments de stockage dont :
 - la définition des méthodes de placement et d'accès
 - la définition et l'intérêt d'un index primaire et secondaire

Pour aller plus loin, vous pouvez regarder...

- la notion de sélectivité dans le cadre de l'utilisation d'un index
- ce qu'est un plan d'exécution sous Postgresql
- la notion d'index statique et dynamique
- les différents types d'index (arbre-B, hachage...)

Nous pouvons donc aborder...

- la gestion de la concurrence